

Hadoop-MapReduce

需求规格说明书

2015年4月

1



1. 范围

1.1. 标识

文档标题: Hadoop-MapReduce 需求规格说明书

版本号: V2.0

1.2. Hadoop-MapReduce 系统概述

MapReduce 是一种编程模型,用于大规模数据集(大于 1TB)的并行运算。概念"Map(映射)"和"Reduce(归约)",和它们的主要思想,都是从函数式编程语言里借来的,还有从矢量编程语言里借来的特性。它极大地方便了编程人员在不会分布式并行编程的情况下,将自己的程序运行在分布式系统上。 当前的软件实现是指定一个 Map(映射)函数,用来把一组键值对映射成一组新的键值对,指定并发的 Reduce(归约)函数,用来保证所有映射的键值对中的每一个共享相同的键组。

1.3. 文档概述

文档用途:本文档主要是介绍 Hadoop-MapReduce 系统需求规格。主要内容:

- 1)以用例图的形式给出 Hadoop-MapReduce 系统功能需求的分解结构,并对用例模型中的参与者和用例进行详细的描述;
 - 2) 使用 RUCM 模型对功能需求进行建模;
 - 3) 描述了与系统实施相关的一些软件、硬件环境的要求。

1.4. 术语和缩略词

缩写、术语	解释
UCM	Use Case Model 用例建模
RUCM	限制性用例模型
Hadoop	是一个由 Apache 基金会所开发的分布 式系统基础架构。
MapReduce	一种编程模型,用于大规模数据集(大于 1TB)的并行运算。
JobTracker	使用文件块信息(物理量和位置)确定 如何创建其他 TaskTracker 从属任务。



TaskTracker	任务处理模块
Map	接受一个键值对(key-value pair),产 生一组中间键值对。
Reduce	接受一个键,以及相关的一组值,将这组值进行合并产生一组规模更小的值。

2. MapReduce 模块中的用例分析

2.1. 系统核心功能用例图

MapReduce 系统中,核心功能的用例图,如图 2-1 所示。



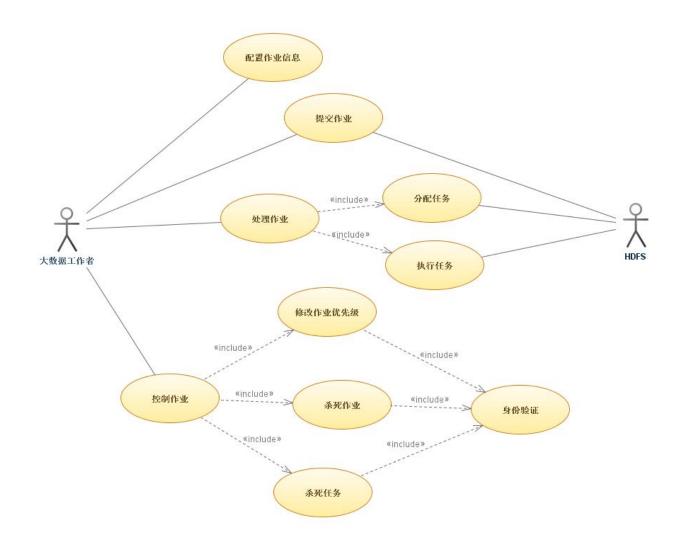


图 2-1 核心功能用例图

由图 2-1 可知,用例图中的 Actor 主要是大数据工作者和 HDFS (分布式文件存储系统),包含配置作业信息、提交作业等用例。



2.1.1. 配置作业信息的需求规格说明



图 2-2 配置作业信息的需求规格说明



2.1.2. 提交作业的需求规格说明

A DESCRIPTION OF THE PROPERTY	0.8	4.20 (4)			
Use Case Name		提交作业			
Brief Description	1 8	数据工作者通过client客户端提交作业			
Precondition	月	用户配置作业信息,完成mapreduce程序编写,打包并通过命令提交			
Primary Actor	J	数据工作者			
Secondary Actors	H	DFS			
Dependency	N	one			
Generalization	N	one			
Basic Flow	CL				
	Ste	数据工作者通过客户端提交作业向JobTracker请求新的作业ID			
(Ondied) ¥		DANAGE STATE			
	2	客户端client向JobTracker请求新的作业ID			
	3	获取JobTracker发来的ID VALIDATES THAT ID不为空			
	4	检查作业的输出说明			
	5	IF 没有指定输出目录或输出目录已被占用 THEN			
	6	作业提交失败,错误抛回给mapreduce程序			
	7	ENDIF			
	8	计算作业的输入分片			
	9	IF 输入路径不存在 THEN			
	10	作业提交失败,错误抛回给mapreduce程序			
	11	ENDIF			
	12	以作业ID创建HDFS目录			
	13	把作业相关文件(应用程序jar包、xml文件及其依赖的文件)上传到HDFS上			
	14	告知JobTracker作业准备执行			
	Pos	tcondition 用户作业提交成功			
Specific Alternative Flow		RFS 2			
		1 client获取到ID为空			
(Untitled) ▼	2	重新向JobTracker请求作业ID			
	Pos	tcondition 等待JobTracker发送作业ID			

图 2-3 提交作业的需求规格说明



2.1.3. 处理作业的需求规格说明

Use Case Name	处理作业			
Brief Descriptio	数据工作者利用MapReduce框架处理作业			
Precondition	作业成功提交			
Primary Actor	JobTracker			
Secondary Actors	TaskTracker			
Dependency	INCLUDE USE CASE 分配任务, INCLUDE USE CASE 执行任务			
Generalization	None			
Basic Flow	Steps			
(Untitled) ▼	1 JobTracker从HDFS获取作业分片信息			
	2 JobTracker初始化作业,得到任务分片			
	3 INCLUDE USE CASE 分配任务			
	4 INCLUDE USE CASE 执行任务			
	Postcondition 作业处理完成,得到计算结果			

图 2-4 处理作业的需求规格说明



2.1.4. 分配任务的需求规格说明

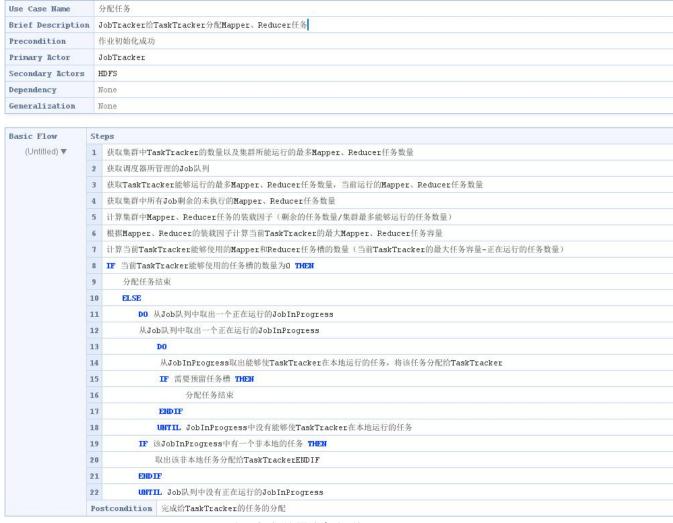


图 2-5 分配任务的需求规格说明

2.1.5. 执行任务的需求规格说明



北京航空航天大学软件工程综合实验

Hadoop-MapReduce

Use Case Name		执行任务		
Brief Description	n	TaskTracker执行任务		
Precondition		TaskTracker接收到JobTracker分配的任务		
Primary Actor		TaskTracker		
Secondary Actors	5	HDFS		
Dependency		None		
Generalization		None		
Basic Flow	St	ceps		
(Untitled) ▼	1	IF TaskTracker当前任务为Mapper任务 THEN		
	2	TaskTracker从HDFS获取作业分片、用户配置等信息		
	3	从输入InputSplit中解析出一个个key/value		
	4	将解析出的key/value交给用户编写的map()函数进行处理,并产生一系列新的key/value		
	5	将输出的key/value按照 key进行排序,并缓存至本地		
	6	ENDIF		
	7	IF TaskTracker当前任务为Reducer任务 THEN		
	8	TaskTracker从各个Mapper任务所在磁盘拷贝中间结果并对结果进行合并		
	9	Reduce Task对中间结果进行合并		
	10	对中间结果(一系列key/value)按照key进行排序		
	11	将排序结果交给reduce()函数进行处理		
	12	将计算结果写到HDFS上		
	13	3 ENDIF		
	Po	stcondition TaskTracker任务执行完毕,等待新的任务		

图 2-6 执行任务的需求规格说明

2.1.6. 控制作业的需求规格说明



北京航空航天大学软件工程综合实验

Hadoop-MapReduce



图 2-7 控制作业的需求规格说明

2.1.7. 身份验证的需求规格说明



图 2-8 身份验证的需求规格说明



2.1.8. 修改作业优先级的需求规格说明



图 2-9 修改作业优先级的需求规格说明

2.1.9. 杀死作业的需求规格说明



北京航空航天大学软件工程综合实验

Hadoop-MapReduce

Use Case Name	杀死作业			
Brief Description	数据工作者杀死指定作业			
Precondition	作业提交成功			
Primary Actor	大数据工作者			
Secondary Actors	None			
Dependency	INCLUDE USE CRSE 身份验证			
Generalization	None			
Basic Flow	Steps			
(Untitled) ▼	1 数据工作者指定要操作的作业ID			
	2 INCLUDE USE CASE 身份验证			
	3 IF 作业控制权限为true THEN			
	4 JobTracker控制TaskTracker暂停执行当前任务			
	5 JobTracker保存当前作业运行信息			
	6 JobTracker系死与用户指定作业ID匹配的作业			
	JobTracker控制TaskTacker系死该作业产生的未完成的任务			
	3 JobTracker根据保存的运行信息控制TaskTracker重新执行			
	9 ENDIF			
	Postcondition 指定作业被杀死			

图 2-10 杀死作业的需求规格说明

2.1.10. 杀死任务的需求规格说明

Use Case Name	杀死任务		
Brief Description	数据工作者杀死指定任务		
Precondition	任务分配完成		
Primary Actor	大数据工作者		
Secondary Actors	None		
Dependency	INCLUDE USE CASE 身份验证		
Generalization	None		
Basic Flow	Steps		
(Untitled) ▼	1 数据工作者指定要操作的任务ID		
	INCLUDE USE CASE 身份验证		
	3 IF 作业控制权限为true THEN		
	4 JobTracker控制TaskTracker暂停执行当前任务		
	5 JobTracker保存当前作业运行信息		
	6 JobTracker控制TaskTracker杀死与用户指定任务ID匹配的任务		
	7 JobTracker控制TaskTracker重新执行		
	8 ENDIF		
	Postcondition 指定任务被杀死		

图 2-11 杀死任务的需求规格说明



2.2. 系统非功能需求用例图

系统非功能需求的用例图,如图 2-12 所示。本实验中我们组仅考虑 JobTracker 容错和 TaskTracker 容错这两个非功能需求。

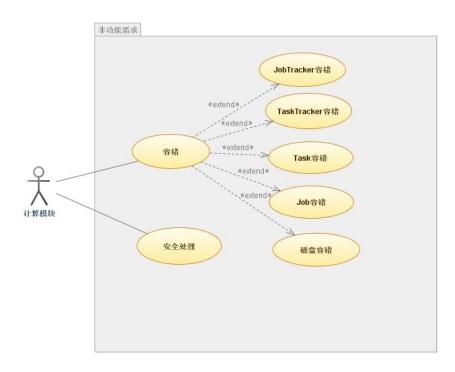


图 2-12 系统非功能需求的用例图



2.2.1. JobTracker 容错的需求规格说明

	Use Case Specification		
Use Case Name	JobTracker容错		
Brief Description	JobTracker容错处理		
Precondition	JobTracker出现故障		
Primary Actor	JobTracker		
Secondary Actors None			
Dependency	None		
Generalization	ralization None		
Basic Flow	Steps		
(Untitled) ▼	1 JobTracker重新启动		
	2 JobTracker检查是否存在需要恢复运行状态的作业		
	3 IF 存在需要恢复的作业 THEN		
	4 JobTracker通过日志恢复这些作业的运行状态		
	5 重新调度未完成的作业		
	6 ENDIF		
	Postcondition JobTracker正常运行		

图 2-13 JobTracker 容错的需求规格说明



2.2.2. TaskTracker 容错的需求规格说明

		Use Case Specification		
Use Case Name	Т	TaskTracker容错		
Brief Description	Т	askTracker容错处理		
Precondition	Т	askTracker出现故障		
Primary Actor	J	obTracker		
Secondary Actors	Т	askTracker		
Dependency		fone		
Generalization	N	fone		
Basic Flow	Ste	Steps		
(Untitled) ▼	1	JobTracker扫描存放所有TaskTracker上次心跳汇报时间的队列		
	2	JobTracker发现某个TaskTracker在10分钟(通过参数配置)内未汇报心跳		
	3	IF TaskTracker上有任务所属作业处于运行或等待状态 THEN		
	4	将这些任务杀掉, 并重新加入任务等待队列		
	5	ENDIF		
	6	IF 任务未运行完成 THEN		
	7	将这些任务杀掉, 并重新加入任务等待队列		
	8	ENDIF		
	9	IF 已经运行完成的Map任务所属作业中的Reduce任务数目不为零 THEN		
	10	将这些任务杀掉, 并重新加入任务等待队列		
	11	ENDIF		
	12	JobTracker将此TaskTracker从集群移除		
	Pos	stcondition TaskTracker被移除		

图 2-14 TaskTracker 容错的需求规格说明

3. 软件、硬件要求

3.1. 软件要求

操作系统: Linux 操作系统。 其他要求: 下载好 Hadoop 源码。



3.2. 硬件要求

3 台 PC 机, 要求内存 4G 以上, 存储空间 100G 以上。

4.参考文献

- [1]Hadoop 权威指南. [译]周敏奇、王晓玲. 北京:清华大学出版社. 2011. 7.
- [2]深入分析云计算之 Hadoop 源码分析
- [3]Hadoop 技术内幕. 董西成. 北京: 机械工业出版社. 2013.5.
- [4]http://baike.baidu.com/view/2902.htm .